

Möglichkeiten und Grenzen ‚smarter‘ HTR für unterschiedliche Sprachen und Schriftsysteme

Achim Rabus


achim.rabus@slavistik.uni-freiburg.de

,Normale‘ HTR und mögliche Konsequenzen

- ,Normal‘: Diplomatische Transkription inkl. aller Besonderheiten bspw. im Bereich von Orthographie, Worttrennung, Interpunktions
- Sehr gute Modelle (vor allem für westliche Schriften/Sprachen) für unterschiedliche Plattformen
- Enorme Vereinfachung für traditionelle (digitale) Editionswissenschaft

HTR-Standardmodelle und Konsequenzen

- Aber: Hat sich im digitalen Zeitalter die klassische Edition überlebt?
„[W]ahrscheinlich schon.“ (Hodel 2024)
- HTR als methodologischer Gamechanger → Massendigitalisierung, Distant Reading, quantitative Ansätze
- **Lernen, Fehler auszuhalten!** (zumindest für bestimmte Anwendungsszenarien)



Gamechanger, Paradigmenwechsel, Konsequenzen

- Im quantitativen Zeitalter (und im Zeitalter knapper Kassen): höherer Rechtfertigungsdruck für kleinteilige, aufwändige, qualitativ orientierte (Editions-)Arbeit
- Impact/Reichweite der Forschung rückt verstärkt in den Fokus
- HTR/KI zur Demokratisierung des Wissens? Zum Abbau von Herrschaftswissen?
- Dazu ‚smarte‘ Modelle nötig (Rabus 2024, Rabus in press)
- Vor allem „Recycling-Ansatz“ zur GT-Erstellung
 - Dank an Mitarbeiter*innen der Projekte MultiHTR 1, 2, Continslav, Quantislav: Lesley Loew, Milanka Matić-Chalkitis, Martin Meindl, Elena Renje, Aleksej Tikhonov

universität freiburg




BAW

BAYERISCHE
AKADEMIE
DER
WISSENSCHAFTEN




Was sind ‚smarte‘ Modelle?

- Jenseits der reinen Transkription zusätzliche Eigenschaften, z.B.
 - Auflösung von Abbreviaturen
 - Transliteration in ein anderes Schriftsystem (mit/ohne Wechsel der Direktionalität)
 - Modernisierung von Orthographie, Interpunktions, Zahlensystem etc.



Glagolisch (Kroatien, 15. Jh.)

- Transkription von Glagolica in Latinica
 - Auflösung von Abbreviaturen
 - Lesehilfe
-
- Dank an Sanja Zubčić, Staroslavenski institut Zagreb; Guido und Jagoda Kappel, Wien



2-18 iže taku krêpostъ podaeš


2-19 i s(ve)timь m(u)č(e)n(i)komъ . da da si n(a)mъ

2-20 onu tvoû m(i)l(o)stъ . i tvoe bl(agoslovle)n

2-21 ie . siê vsa b(og)u sl(a)vna . plna

2-22 g(lago)lъ i pêniê . i ta sl(a)vitъ t

Kyrillisch: 11.–16. Jh.: Modelle für unterschiedliche Zielgruppen



Beibehaltung der Ligaturen und
Abkürzungen

Für modernisierende Editionen und Nicht-Philolog*innen

Russisch (20. Jh.)

- Orthographiereform 1918
- Abschaffung verschiedener Grapheme
- Modell mit modernisierenden Fähigkeiten



Dokumente aus dem Prozhito-Projekt: Tagebücher, insb. Anfang 20. Jh.

все страшно дорого и достать негде один
полк стоит в год 3. миллиона. Когда я вышел,
из госпиталя то мне навстречу *и*
мы с ним пошли гулять встретил Доктор *и*
затем он ушел и мы пошли в дом товари
щества к сестрам тал сидел ио 8 ч. муся»
я стала писать дневник слышу пришл офица

- 1-1 все страшно дорого и достать негде один
- 1-2 полк стоит в год 3. миллиона. Когда я вышел
- 1-3 из госпиталя то мне навстречу *и*
- 1-4 мы с ним пошли гулять встретил Доктор *и*
- 1-5 затем он ушел и мы пошли в дом товари
- 1-6 щества к сестрам тал сидел ио 8 ч. муся»
- 1-7 шлу
- 1-8 у *и* пошли к *и* вмлесте с
- 1-9 нами. Вернулись мы поужинали и разошлись
- 1-10 Я стала писать дневник слышу пришл офица

Automatische
Modernisierung:
ѣ > е
і > и

Dank an das Prozhito-Projekt
Sankt Petersburg

Dokumente aus dem Prozhito-Projekt:

Tagebücher, insb. Anfang 20. Jh.

все страшно дорого и достать негде один
полк стоит в год 3. миллиона. Когда я вышел
из госпиталя то мне навстречу *точка* и
мы с ним пошли гулять встретил Доктор *точка*
затем он ушел и мы пошли в дом товари
щества к сестрам тал сидел ио 8 ч. муся»
у *точка* пошли к *точка* вмлесте с
нами. Вернулись мы поужинали и разошлись
Я стала писать дневник слышу пришл офица

1-1 все страшно дорого и достать негде один

1-2 полк стоит в год 3. миллиона. Когда я вышел

1-3 из госпиталя то мне навстречу <name> и

1-4 мы с ним пошли гулять встретил Доктор <name>

1-5 затем он ушел и мы пошли в дом товари

1-6 щества к сестрам тал сидел ио 8 ч. муся»

1-7 шлу

1-8 у <name> пошли к <name> вмлесте с

1-9 нами. Вернулись мы поужинали и разошлись


1-10 Я стала писать дневник слышу пришл офица

Automatische
Modernisierung:
ѣ > е
і > и

Auslassung von є am
Ende der Wortformen

Jiddisch (16. Jh.)

- Transliteration
- Direktionalität
- Diakritika
- Zugang auch für Nicht-Spezialist*innen
- Zwei öffentliche Modelle
- Ähnlich auch für Osmanisch
- Dank an Astrid Lembke (Mannheim)



- 1-1 nacht ouſén blib, do dar-schrakh der melech joel er
1-2 gèdoch mán het in irgènt gèbangén. un` er lif-
1-3 blukš in daš kaštel , do vand er den ganzen
1-4 ozer nit. un` in der kišt vand' er den brib
1-5 er d o er in lai't, do diš er sich seién hor ouš

Stenographie

- Endgegner von HTR: keine Eins-zu-eins-Relation, teilweise extrem verkürzt
- Optisches Signal tw. weniger aussagekräftig → starkes Sprachmodell (und damit große Menge an Trainingsdaten) nötig
- Drei Systeme: Stolze-Schrey (eher Schweiz/eher protestantisch), Gabelsberger (eher Deutschland/eher katholisch), Deutsche Einheitskurzschrift
- Vier öffentliche Modelle (2x Gabelsberger)



- Tw. synthetische Trainingsdaten
- Verbessert CER, aber nicht Real-World-Performance

Name Search	Wörter	CER	Sprache
Gabelsberger_natural	429 663	13.38%	GER
Faulhaber	259 537	12.17%	GER
Stolze-Schrey_combined	23 023	9.50%	GER
DEK_German_combined	144 709	9.50%	GER

Erfolgreiche HTR (Faulhaber Gabelsberger)

Wegfahrt. P. A. summa cum laude, et. b. f. u. c. 2.
zur, 2. April p. 2. put. 9 lex. Esst. I. pm - 0 em, m.
d. s. s. 6. 2. e. o. a. - h. - t. - v. l. y. e. h. n. - f. , o. f
f. 73h, 2. 2. r. f. u. - 1. 8. trecento, - f. f. d. o
f. r. - p. c. 2. f. u. v. z. n. k. l.

1-1 Ohne auf die heutige Verhältnisse zukommen. Die Trüftung summar cm lande, die ersten Staatsprüfung als das zwei.


1-2 in Bayern im Aprrt die zweite. Dafür sollte er sich nicht darüber a wieder überabiten. Nicht krank sei bis der eigentliche Befuf beginnt

1-3 würder es überalnehmen wenn ich ihm die wirtschaftlichen Sorge erlichtern wollte - mit der Entscheidung haben das nichts zu tun. Er zegt, sein Vater

1-4 arbeite noch mit 73 Jahren, er selber habe keine Geschenke angenommen. trecento, er zieht zuerst die Hand

1-5 zurück. Es war eine Pause weil ich im Vorzimmer bei Zinkl.

Nicht erfolgreiche HTR (Generisch Gabelsberger)



1-1 e de me e e

1-2 nachs Brief an Junger Enweruf. bleigte Sittation die aSominik im Malstom. I Sta sagt sich ab bisse durch sie stinme als für sie.

1-3 selche behrtischen Ppaize in Schulwerte wie in Esseziell war bei von asn


1-4 die Urschlag an; die Henk schligt zu.

1-5 ch Megs. auf: Hoo 2414 (antat. Unter dem Anfluss von Ontinge).

1-6 sonderbar befedete Schnecke durch den schnen Brief von Buro Brekem zu Land und mehr wirt; sah plötzlich wieder eine Werk und

Erfolgreiche, aber synthetische HTR (Stolze-Schrey)


- Modell leider zu klein für vernünftige Real-World-Performance



- 1-1 doch die Pflicht seine Bereitwilligkeit anzubitten wenn man jemanden in
1-2 einer Bedrängnis sehe, da ergebe sich doch natürlich die Pflicht
1-3 zu helfen ...
2-1 die Pflicht ... seine bereitwilligkeit anzubitten die Pflicht, den
2-2 versuch zu machen ... Sie meinen Also auch, Sie auch, man habe die Pflicht ... die

Erfolgreiche natürliche HTR (DEK)

- Booster durch Kombination von natürlicher und synthetischer GT




1-1 27.3.42.

- 1-2 Ich erfahre durch einen Anruf von Leutnant Hofweber (adjutant 505) dass ich zur I./Flak
1-3 Regiment 4 als Batterie schaff (Schwer) versetzt bin. Ich kann es im erste Augenblick gar nicht fassen dass Mein heißest
1-4 Wunasch so schnell in Erfahrung gegangen ist. Nun muss ja alles gut werde. Leider kann ich nicht am selben Tag abfahren
1-5 da die Abteilung mein Marschzittelefonisch nicht verstehen konnte. Als mein Eechfolger ist Oberleutnant Reck bestimmt.
1-6 nun hate er es ja endlich geschaft. Hoffentlich verdilebt er mir meine kurz aArbeit bei der Batterie in Seinem überort nicht.

Qualitativ tw. besser als Expert*innenwissen

- In GT hier < Hoch >, da Transkriptionsexpertin dies nicht entziffern konnte
- Hochablass: Stauwehr am Lech in Augsburg



1-1 4. August 46

1-2 litg ! Es wird ein herrlicher Sommertag. Ich biege mich nachmittags in den Fluten

1-3 des Lech am Hochblas.

Wie weiter?

- Smarte und komplexe HTR mit beachtlichen Ergebnissen, aber dennoch teilweise an der Grenze der Brauchbarkeit für manche Einsatzzwecke (Steno-Editions-Community...)
- LLMs zur Post-Korrektur? Unseren Experimenten zufolge nur bei modernen Resourced Languages hilfreich, bei anderen nicht hilfreich bis katastrophal schädlich
- Bessere Engines? Transformer (TrOCR) hilfreich, erste ermutigende Ergebnisse für latein-basierte Schriftsysteme (Romein et al. 2024)
 - Benutzerfreundlichkeit? Skalierung? Hardware?
- Andere Engines/Systeme? Wie sinnvoll Transkribus-GT nachtrainieren?
 - eScriptorium Trans/Conformer, PERO Transformer, OCR4all?
- Reflexion über Aufgaben/Zielgruppen/Outreach/GT- und Modell-Management

